- Proceso de entrenamiento Q-Learning Tabular:

④ Exploración y Persistencia

Al final de cada episodio el valor ε reduce gradualmente para que el agente confie mas en su tabla

① Discretización ⟹ ② Bucle de entrenamiento ⟹ ③ Actualizacion del conocimiento

$\frac{dy}{dt} \rightarrow \Delta y_k$

Estados: Posición
Velocidad
Angulo
$x \in \mathbb{R}$

⇓

Creación Bins
$x \in D_i$
Donde
$D_i = \{x \in \mathbb{R} \mid a_k \leq x \leq a_k\}$

Inicialización
ε

Acción al azar (Explorar)

Elegir la mejor opción según la tabla Q (Explotar)

Ejecución

Se ejecuta acciones en el entorno, recibiendo recompensas

- Cálculo del Error de Diferencia temporal. Estimación del valor futuro (flujo descontado de recompensas) gamma γ ⇒ Tasa de descuento
- Actualización de q Tabla. la modificación de esta tabla depende de la tasa de aprendizaje α

- Proceso de entrenamiento Deep - Q - Network:

q-net

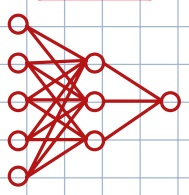

Es el piloto que esta aprendiendo. Es la que decide que accion tomar

Target Net

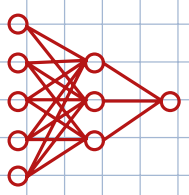

Copia identica de q-net pero congelada, para servir como punto de referencia

1. Decisión y Acción
   ↳ Agente observa el estado actual s (8 valores lander)
   q net predice cuanto premio ganaría con cada una de las 4 acciones

2. Almacenamiento en el Buffer
   ↳ El resultado de las acciones y sus recompensas se almacenan.

Entrenamiento

3. Repaso:
   El agente toma una muestra del Buffer (Un Batch) y para cada muestra q-net toma una accion prediciendo una recompensa y target net establece el valor real (el estado de la nave) para esa determinada acción

4. Back propagation
   A través del MSE, se calcula el error entre lo establecido por q-net y lo que se establece en la referencia para ajustar pesos y sesgos para que q-net sea más precisa

5. Sincronización
   Cada cantidad de episodios copiamos q-net a target net para actualizar